

Učenje sa greškama

Tanja Gavrić 1065/2025

Jun 2026

Uvod

2016. godina - NIST objavljuje takmičenje za najbolje postkvantne kriptosisteme.

8 godina kasnije, prvi standardizovan KEM algoritam je ML-KEM, zasnovan na ranijem algoritmu CRYSTALS-Kyber.

Cilj: prikaz osnovne matematičke ideje iza ovog protokola.

Tok prezentacije

teški problemi na rešetkama → učenje sa greškama → Kyber

Agenda

1. Složenost problema
2. Učenje sa greškama, LWE
3. Učenje sa greškama u prstenu, Ring-LWE
4. Kyber

Agenda

– 1. Složenost problema

2. Učenje sa greškama, LWE

3. Učenje sa greškama u prstenu, Ring-LWE

4. Kyber

Nije dovoljno reći: „*Problem je težak.*“

Teorija složenosti

NP-kompletni problemi - najteži problemi klase NP.

Pažnja

NP-kompletno $\neq$ automatski dobro za kriptografiju

Primjer

Merkle-Helman kriptosistem zasnovan na NP-kompletnom problemu ranca, može se razbiti tehnikama zasnovanim na LLL algoritmu.

Problem

NP-kompletnost garantuje samo težinu *najgoreg slučaja*, a nama je potrebna težina *prosječnog slučaja*.

Rješenje

Redukcija:

najgori slučaj $\implies$ prosječan slučaj

Problem

NP-kompletnost garantuje samo težinu *najgoreg slučaja*, a nama je potrebna težina *prosječnog slučaja*.

Rješenje

Redukcija:

najgori slučaj $\implies$ prosječan slučaj

Problemi na rešetkama imaju ovakve redukcije!

problemi na rešetkama $\implies$ LWE

Agenda

1. Složenost problema

– 2. Učenje sa greškama, LWE

3. Učenje sa greškama u prstenu, Ring-LWE

4. Kyber

Primjer bez grešaka

$$2s_1 + s_2 = 7,$$

$$s_1 + 3s_2 = 11,$$

$$3s_1 + 2s_2 = 12.$$

Učimo skrivenu linearnu vezu:

$$s = (2, 3).$$

Primjer sa greškama

$$2s_1 + s_2 = 7+1,$$

$$s_1 + 3s_2 = 11-1,$$

$$3s_1 + 2s_2 = 12+2.$$

Mala greška kviri jednostavnost početnog problema.

Učenje sa greškama, LWE (Learning with errors)


Neka je q prirodan, najčešće prost broj, i neka je $\mathbb{Z}_q = \mathbb{Z}/q\mathbb{Z}$ skup ostataka po modulu q . Neka su matrica $A \in \mathbb{Z}_q^{n \times m}$, tajni vektor $s \in \mathbb{Z}_q^m$, i vektor greške $e \leftarrow D_{\mathbb{Z}^n, \sigma}$.

$$b = A \cdot s + e \pmod{q}$$

A, b su poznati s, e su nepoznati

Geometrijska veza sa rešetkama

$$\mathcal{L} = \Lambda_q(A^T) = \{x \in \mathbb{Z}^n \mid x \equiv A \cdot z \pmod{q}, z \in \mathbb{Z}^m\}$$



$A \cdot s \in \mathcal{L}$, $b = A \cdot s + e$, b je blizu rešetke.

Redukcija

Procenjujemo normu vektora e kao $\|e\| \leq \frac{2 \cdot \sigma \cdot \sqrt{m}}{\sqrt{2 \cdot \pi}}$.

Može se poistovijetiti sa BDD_α problemom, gde je $\alpha = \frac{2\sigma\sqrt{m}}{\sqrt{2\pi}\lambda_1()}$.

Redukcija

$$BDD_\alpha \implies LWE$$

Protokol javnog ključa učenja sa greškama

Generisanje ključa

$$\begin{aligned} s &\in \mathbb{Z}_q^n & a_i &\in \mathbb{Z}_q^n & e_i &\leftarrow D_{\mathbb{Z},\sigma} \\ b_i &= a_i \cdot s - 2 \cdot e_i \pmod{q} \end{aligned}$$

Enkripcija

$$\begin{aligned} c &= \sum_{i=1}^m \iota_i a_i \pmod{q} & \iota_i &\in \{0, 1\} \\ d &= M - \sum_{i=1}^m \iota_i b_i \pmod{q} \end{aligned}$$

Dekripcija

$$\begin{aligned} c \cdot s + d \pmod{q} &= \left(\sum_{i=1}^m \iota_i a_i \right) \cdot s + M - \sum_{i=1}^m \iota_i b_i \pmod{q} \\ &= \sum_{i=1}^m \iota_i (a_i \cdot s) + M - \sum_{i=1}^m \iota_i (a_i \cdot s - 2e_i) \pmod{q} \\ &= M + 2 \sum_{i=1}^m \iota_i e_i \pmod{q} = M + \eta \end{aligned}$$

Agenda

1. Složenost problema
2. Učenje sa greškama, LWE
- 3. Učenje sa greškama u prstenu, Ring-LWE
4. Kyber

Učenje sa greškama u prstenu

Nedostatak učenja sa greškama

Matrice izazivaju veliku memorijsku složenost. Dakle, LWE ima velike ključeve.

Rješenje - matrice postaju polinomi

$$b = A \cdot s + e \quad \longrightarrow \quad b = a \cdot s + e$$

Umjesto u $\mathbb{Z}_q^{n \times m}$, radićemo u prstenu polinoma $R_q = (\mathbb{Z}/q\mathbb{Z})[X]/(F(X))$.

Protokol javnog ključa učenja sa greškama u prstenu

Generisanje ključa

$$\begin{aligned} s, e &\leftarrow D_{R, \sigma} & a &\in R_q \\ b &= a \cdot s + p \cdot e \pmod{q}. \end{aligned}$$

Enkripcija

$$\begin{aligned} e_0, e_1, e_2 &\leftarrow D_{R, \sigma} \\ c_0 &= b \cdot e_0 + p \cdot e_1 + M \pmod{q} \\ c_1 &= a \cdot e_0 + p \cdot e_2 \pmod{q} \end{aligned}$$

Dekripcija

$$\begin{aligned} c_0 - c_1 \cdot s &= (b \cdot e_0 + p \cdot e_1 + M) - (a \cdot e_0 + p \cdot e_2) \cdot s \pmod{q} \\ &= ((a \cdot s + p \cdot e) \cdot e_0 + p \cdot e_1 + M) - (a \cdot e_0 \cdot s + p \cdot e_2 \cdot s) \pmod{q} \\ &= p \cdot e \cdot e_0 + p \cdot e_1 + M - p \cdot e_2 \cdot s \pmod{q} \\ &= M + p \cdot (e \cdot e_0 + e_1 - e_2 \cdot s) \pmod{q} = M + p \cdot \eta \end{aligned}$$

Agenda

1. Složenost problema

2. Učenje sa greškama, LWE

3. Učenje sa greškama u prstenu, Ring-LWE

4. Kyber

4.1 Modulno učenje sa greškama

4.2 Module Lattices Key Encryption Mechanism, ML-KEM

Modulno učenje sa greškama

Nedostatak Ring-LWE pristupa

Za Ring-LWE postoje redukcije iz najgoreg u prosječan slučaj, ali se one odnose samo na probleme nad *idealnim* rešetkama.

Ideja Module-LWE

Umjesto jednog polinoma, radimo sa k -strukim Dekartovim proizvodom prstena polinoma R_q :

$$\mathbb{Z}_q^n \longrightarrow R_q^k$$

$$A \in R_q^{k \times k}, \quad s, e \in R_q^k, \quad b = A \cdot s + e \pmod{q}.$$

Module-LWE čuva efikasnost Ring-LWE pristupa, ali daje fleksibilniju strukturu.

Kyber / ML-KEM u fazama

Module-LWE $\longrightarrow$ PKE šema $\longrightarrow$ KEM protokol

1. Osnovna PKE (Public Key Encryption) šema

Na osnovu Module-LWE problema generiše se javni ključ:

$$b = A \cdot s + e \pmod{q}$$

gde je A javna matrica nad $R_q^{k \times k}$, a s i e su mali tajni vektori polinoma. Enkripcija i dekripcija funkcionišu slično kao šeme LWE i Ring-LWE.

2. KEM (Key Encapsulation Mechanism) protokol

Kyber primjenjuje „Fujisaki-Okamoto“ transformaciju

KeyGen $\rightarrow$ Encaps $\rightarrow$ Decaps.

Primjena Kyber-a

- *CNSA 2.0* — Commercial National Security Algorithm Suite
- *Google* — za podatke u tranzitu
- *Signal* — zaštita poruka
- *Apple* — iMesssage
- *Amazon* — AWS Key Management Service
- *IBM* — prototip uređaja za skladištenje podataka